시작 위치 미세 이동에 따른 AudioSeal의 검출과 메시지 복원 간 괴리 분석*

이재윤[0], 전상훈
수원대학교
l2e.ajyoon@gmail.com, shjeon.usw@gmail.com

Analysis of the Gap between Detection and Message Recovery in AudioSeal under Small Start Offsets

Jaeyoon Lee[0], Sanghoon Jeon
The University of Suwon
l2e.ajyoon@gmail.com, shjeon.usw@gmail.com

요 약

워터마크를 검출해도 함께 삽입한 16비트 메시지가 정확히 복원되는 것은 아니다. 공개 AudioSeal과 VCTK 10화자 20발화로 이를 평가했다. 앞 1초를 제거한 기준선에 15개 고정 추가 절단량을 적용한 300조건 중, 195조건(65.0%, 95% 구간 59.0~71.0%)에서 검출은 통과했지만 메시지는 틀렸다. 320개 정렬 중 평균 logit margin이 가장 큰 후보를 고르면 추가 절단 조건을 모두 복원했으나 기준선 20건 중 2건은 오답으로 바뀌었다. 오답 비트에서도 큰 출력값이 나타났다. 낮은 margin일 때만 탐색하는 규칙은 같은 자료의 320조건을 모두 복원했지만, 사후에 도출한 결과이므로 독립 검증이 필요하다.

1. 서 론

AudioSeal[1]은 음성에 사람이 듣기 어려운 워터마크 신호를 넣어 출처 확인을 돕는다. 함께 삽입하는 16비트 코드를 메시지라고 부른다. 검증자는 워터마크의 존재를 검출하고 메시지를 읽은 뒤, 등록 코드와 대조해 출처를 판정한다. 이를 귀속이라고 한다.

편집이나 재유통 중 앞부분이 잘리면 검증자는 생성 당시와 다른 시작점에서 음성을 검사한다. 검출은 통과해도 메시지가 틀릴 수 있다. 이 경우 등록 규칙에 따라 잘못된 귀속이나 판정 보류가 발생할 수 있다.

본 연구는 앞부분을 조금 더 잘랐을 때 검출과 메시지 복원이 어떻게 달라지는지 조사한다. 검출을 통과한 오답을 집계하고, 점수에 따라 출력을 보류하는 방법과 여러 시작점을 검사하는 정렬 탐색을 비교한다. 탐색이 기존 정답을 오답으로 바꾸는 사례도 분석한다.

2. 관련 연구

WavMark[2]와 SyncGuard[3]는 검사 시작점이 달라지는 동기화 문제를 다룬다. AudioSeal[1]도 존재 검출과 메시지 기반 귀속을 구분해 평가한다.

Kumara[4]는 작은 이동에 따른 메시지 훼손을 언급하지만 동기화 공격을 정량 평가에서 제외했다. 공개 이슈[5]에는 검출은 유지되면서 메시지가 틀리는 사례가 보고됐다. Yang 등[6]은 다른 체계에서 정렬 탐색과 서명 검증을 결합했다. XAttnMark[7]는 교차 주의로 메시지를 읽으며, Wang 등[8]은 학습 복호기로 시간별 출력을 집계한다. 본 연구는 재학습 없이 공개 구현의 평균 집계를 사용하며, 미세 정렬에 따른 비트 출력과 후보 선택의 손실을 분석한다.

3. 실험 방법

3.1 자료와 모델

VCTK 0.92[9] mic2 영어 음성을 SciPy resample_poly로 16kHz 단일 채널로 변환했다. 공개 사전학습 audioseal_wm_16bits와 audioseal_detector_16bits를 재학습 없이 사용했다. 파일명 SHA256의 앞 4바이트를 시드로 발화별 16비트 메시지를 생성하고, 워터마크를 배율 조정 없이 원본에 더했다. 대응 비삽입 음성(Clean)을 대조군으로 썼다. 모델 구현: https://github.com/facebookresearch/audioseal. 연구 자료: https://github.com/jae-yoonlee/audioseal-offset-analysis.

3.2 평가 지표와 정렬 탐색

각 샘플의 검출 점수가 0.5를 넘는 비율을 q라 하고, 연구용 기준 q>0.5로 파일을 검출했다. 이는 검출 점수 자체의 평균과 다르다. 원 논문[1]은 오탐률에 맞춰 파일 판정 문턱을 보정한다. 정확 복원은 16비트가 모두 삽입 메시지와 일치한 경우다.

logit은 비트를 0과 1 중 어느 쪽으로 출력할지 정하는 신경망 값이다. 수신 구간에서 시간 평균한 logit이 양수면 1, 아니면 0으로 복원했다. 비트별 평균 logit의 절댓값을 16개 비트에 걸쳐 평균한 값을 margin, 그중 최솟값을 최

* 본 연구는 수원대학교 전상훈 교수의 지도하에 수행되었다.

소 비트 margin으로 정의했다. 둘 다 실제 정확도를 나타내는 확률은 아니다.

추가로 제거한 샘플 수를 r, 검사 전에 앞에 붙인 영값 샘플 수를 p, 검사한 p의 개수를 K라 한다. 정렬 탐색은 p를 바꿔 여러 후보를 검사하는 절차다. 예를 들어 r=80일 때 p=80을 붙이면 격자 위상을 맞출 수 있지만, 잘린 음성은 되살리지 못한다. 인코더의 다운샘플링 비율 8, 5, 4, 2의 곱은 320이다. 앞 1초는 16000=50×320샘플이므로 상대 정렬 d=p−r가 0이면 원래 격자 위상에 해당한다. p는 0부터 320/K 간격으로 319까지 사용하며 K={1,4,16,64,320}이다. K=4는 p={0,80,160,240}, K=1은 단일 검사다. 추가 영값을 제외한 수신 구간에서 q와 메시지를 구하고 q 또는 margin 최대 후보를 골랐다. 동점이면 최소 p를 쓰며 정답은 채점에만 사용했다.

3.3 실험 절차

별도 10화자 50발화로 탐색한 뒤, 미사용 화자 중 ID순 p257–p266을 골랐다. 각 화자의 파일명순 적격 발화(단일 채널, 6–15초) 앞 2개, 총 20발화를 선택했다. 출력에 따라 화자나 발화를 바꾸지 않았다.

앞 16000+r샘플을 제거했다. r=0도 앞 1초를 제거한 기준선이며 무편집 입력이 아니다. 추가 절단량 15개는 1~319에서 seed=20261016으로 중복 없이 추출했다. r 목록은 {0,25,56,64,82,106,127,156,172,178,194,220,227,239,290,299}이다. 추가 절단 300조건은 20발화×15개 r이며, 기준선 20조건과 구분했다.

발화와 r은 결과 확인 전에 고정했다. 표 1과 표 3은 이 확인 평가의 결과다. 4.2~4.4절은 같은 자료를 다시 분석한 사후 개발 결과다. 95% 구간은 화자를 묶음으로 재표집하는 bootstrap 10,000회로 계산해 같은 화자의 반복 관측을 함께 유지했다.

4. 실험 결과

4.1 검출과 메시지의 괴리

표1. 사전 고정 확인의 검출과 정확 복원(건수/분모)

조건	단일 검출	단일 정확	K320 q 정확 복원	K320 margin 정확 복원
기준선 r=0	20/20	20/20	12/20	18/20
이동r>0	204/300	9/300	166/300	300/300
전체	224/320	29/320	178/320	318/320

단일 검사는 기준선 20건을 모두 검출하고 복원했다. 추가 절단 300조건에서는 204건(68.0%)이 검출됐다. 이 중 정확 복원은 9건으로, 195건은 검출을 통과했지만 메시지가 틀렸다. 전체 추가 절단 조건의 65.0%[59.0~71.0]이며, 검출된 204건만을 분모로 삼으면 95.6%다.

전체 비트 정확도는 60.2%였다. 비트 평균과 달리 16비트 전체 일치는 3.0%이므로, 검출과 메시지 전체 일치를 함께 보고했다.

K320의 검출은 두 선택법 모두 300/300이었다. 추가 절단의 정확 복원은 margin 선택 300건, q 선택 166건이었다. 기준선까지 포함한 차이는 43.75%p[30.6~56.9]다. 기준선 복원은 각각 18/20, 12/20으로 줄었다. Clean은 모든 후보에서 q<0.31로 관측 오탐이 없었다.

4.2 오답의 두 양상

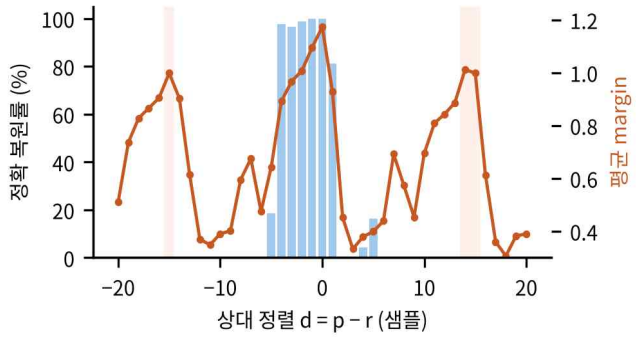


그림 1 상대 정렬 d별 정확 복원률(막대, 왼쪽)과 평균 margin(선, 오른쪽). 분모: d<0 300, d≥0 320조건(r=0은 d≥0). 음영: d=−15,+14,+15.

저장 후보 102,400개(20발화×16개 r×320개 p)를 분석했다. d=0은 원래 격자 위상이며 d≠0은 상대적으로 어긋난 상태다.

이하 |logit|은 비트별 시간 평균 logit의 절댓값이다. 정렬된 d=0 비트의 중앙값은 1.17, 하위 5% 값은 0.85였다.

(가) 정렬이 어긋난 단일 출력: 검출된 추가 절단 출력은 정답 9건까지 모두 margin≤0.89로, 기준선 정답의 최솟값 1.08보다 낮았다. 오답 비트의 |logit| 중앙값은 0.36이었다[그림 2]. 오류 수는 1~12비트(중앙값 6)였다. 이 표본에서 낮은 margin은 오답 여부보다 정렬이 어긋난 상태와 관련됐다.

(나) 원래 정렬에 가까운 오답: d=−15,+14,+15의 940후보는 모두 검출됐지만 정확 복원은 0%였다. 평균 margin은 약 1이었고, 오답 비트 |logit| 중앙값 1.05는 정답 비트 1.06과 비슷했다. 오답 비트의 72%가 d=0의 하위 5% 값(0.85)을 넘었다[그림 2]. 따라서 큰 평균 margin을 정답 비트의 기여만으로 설명할 수 없다. 다만 |logit|은 정확 확률이 아니다.

근접 오답은 2~5비트(중앙값 3)가 달랐다. 특정 비트 위치에 오류가 집중됐지만, 발화마다 메시지도 달라 음성과 메시지의 영향을 분리하지 못했다.

중심 밖 일부 위치에서도 정확 복원률 25~52%, 평균 margin 0.43~0.52가 관측됐다. 이는 모든 비정렬 출력이 같은 양상으로 틀리지는 않음을 보여준다.

4.3 점수에 따른 판정 보류와 정렬 탐색

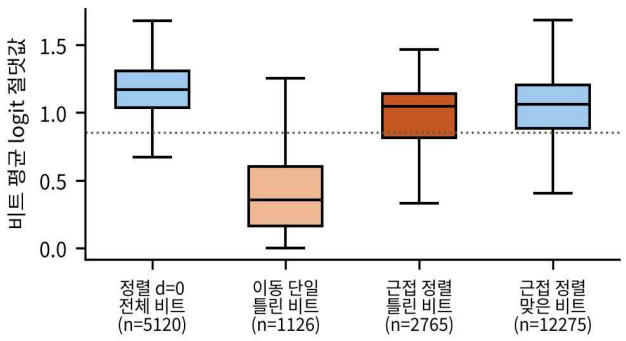


그림 2 비트 |logit| 분포: 정렬, (가) 오답, (나) 오답, 정답 순. 상자: 사분위 범위, 수염: 1.5 IQR, 점선: 정렬 하위 5%(0.85).

문턱 미만의 출력을 보류하는 방법을 평가했다. 두 margin 점수의 정답과 오답 구분력은 AUC로 비교했다. 이는 임의의 정답 점수가 오답 점수보다 높은 비율로, 동점은 절반으로 센다. 0.5는 무작위, 1은 완전 구분이다.

표2. 이동조건(r>0) 검출 출력의 정답과 오답을 구분하는 AUC

점수	단일(정답9/204)	K320 q(정답166/300)
평균margin	0.711 [0.615-0.816]	0.942 [0.877-0.984]
최소비트 margin	0.899 [0.851-0.951]	0.984 [0.969-0.997]

단일 검사에서 수락한 출력 중 오답 비율을 0, 5, 10, 20% 이하로 제한하면 어떤 문턱에서도 추가 절단의 정답 출력은 남지 않았다. 평균 margin은 오답 23건이 정답 9건 모두보다 높았다. 이 표본에서는 점수에 따른 보류만으로 정답을 남기기 어려웠다.

정렬 탐색은 선택 점수에 따라 성능이 달랐다(표 3). K320의 98조건에서는 q≥0.9995인 후보가 여럿이었다. 값이 가깝다는 사실만으로 정확한 동점을 뜻하지는 않는다. 정확 복원은 q보다 margin 선택에서 높았다.

표3. 후보수K에 따른 정확 복원(전체320조건)과 검사지연

K	q 선택	margin 선택	지연(ms)
1	29	29	11.6
4	56	60	45.7
16	77	110	180.8
64	129	257	723.3
320	178	318	3610.2

지연은 margin 선택 기준으로 RTX 3090에서 배치 1로 후보를 순차 검사한 값이다.

기준선 오답 2건은 d=15와 14를 선택한 경우다. margin 1.12~1.16은 정확 복원 후보의 1.07~1.27과 중첩됐다. 최소 비트 margin 선택은 기준선 20/20을 보존했으나 추가 절단 복원이 298/300으로 줄었다.

4.4 낮은 margin에서만 실행하는 조건부 탐색

단일 검사를 통과하고 margin≥τ이면 그대로 쓰고, 아니면 K320 margin 탐색을 실행하는 규칙을 사후에 만들었다. 관측된 추가 절단 margin 최댓값과 기준선 정답 최솟값은 각각 약 0.89와 1.08이었다. 이 두 집단 사이의 문턱을 시험했다.

두 집단 사이의 문턱에서 320/320을 정확히 복원했다. 넓은 범위 τ=0.80~1.19에서도 318~320/320이었다. 다만 93.75%가 탐색하므로 비용 절감은 작다. 같은 자료로 규칙을 만들고 평가했으므로 독립 검증 결과가 아니다.

근접 오답의 margin이 τ를 넘으면 이 규칙도 실패할 수 있다. 영값 후보를 위상 (p-r) mod 320으로 묶었을 때 검출 통과, 메시지 오류, margin≥τ를 동시에 만족한 비율은 τ=0.89, 1.00, 1.08에서 2.50%, 0.61%, 0.09%였다. 영값을 붙인 후보의 통계이므로 실제 추가 절단 위험의 추정값은 아니다.

5. 논의 및 한계

귀속 결과는 등록 규칙에 달려 있다. 정답을 포함한 균등 무작위 고유 코드 M개에 정확 일치만 수락하면 오귀속 기대값은 P(검출 통과 오답)×(M-1)/65535다. 이번 추가 절단의 M=10^3, 10^4 기대값은 0.99%, 9.92%다. 이는 가정한 코드북의 계산값이며 실제 서비스의 인증 실패율은 아니다.

한 모델과 VCTK 10화자 20발화의 16개 제거 위치에 한정된다. 표 1과 표 3 외 분석은 사후 개발 결과다. 원 논문[1]의 오탐률 보정과 검출 샘플 한정 집계 대신 q>0.5와 수신 구간 전체 평균을 사용했다. 저장 자료에 시간별 출력이 없어 원 절차를 재구성하지 못했다. 무편집 입력, 다른 코퍼스, 코덱, 의도적 공격은 미평가다. 비트별 오류 원인과 조건부 규칙은 새 음성과 메시지에서 확인해야 한다.

6. 결론

고정한 추가 절단 300조건 중 195조건(65.0%)에서 검출은 통과했지만 메시지는 틀렸다. K320 margin 탐색은 추가 절단 조건을 모두 복원했으나 1초 제거 기준선 20건 중 2건을 오답으로 바꿨다. 오답 비트에서도 큰 |logit|이 나타나, 큰 margin만으로 정확성을 보장할 수 없었다. 낮은 margin에서만 탐색하는 규칙은 같은 개발 자료에서 이 손실을 막았다. 실제 근접 절단과 새 화자에서 규칙을 확인하고, 시간별 출력을 보존해 원 논문의 집계 절차와 비교해야 한다.

참고문헌

[1] R. San Roman, P. Fernandez, H. Elsahar, A. Défossez, T. Furon, and T. Tran, "Proactive Detection of Voice Cloning with Localized Watermarking," Proceedings of the 41st International Conference on Machine Learning (ICML), PMLR, Vol. 235, pp. 43180-43196, 2024. https://proceedings.mlr.press/v235/san-roman24a.html

[2] G. Chen, Y. Wu, S. Liu, T. Liu, X. Du, and F. Wei, "WavMark: Watermarking for Audio Generation," arXiv:2308.12770v3, 2024. https://arxiv.org/abs/2308.12770v3

[3] Z. Gan, X. Hu, S. Li, Z. Qian, and X. Zhang, "SyncGuard: Robust Audio Watermarking Capable of

Countering Desynchronization Attacks," arXiv:2508.17121v2, 2025. https://arxiv.org/abs/2508.17121v2
[4] L. Kumara, "How Fragile Is Your Watermark? Training-Free Structural Removal of Neural Audio Watermarks," arXiv:2608.16566v1, 2026. https://arxiv.org/abs/2608.16566v1
[5] royrs, "Watermark contained only in the 100 first samples," facebookresearch/audioseal, GitHub Issue #52, 2024 (accessed Oct. 23, 2026). https://github.com/facebookresearch/audioseal/issues/52
[6] G. Yang, A. Ghasemian, N. Mehrabi, and H. Hosseinmardi, "Asymmetric Phase Coding Audio Watermarking," arXiv:2605.07241v2, 2026. https://arxiv.org/abs/2605.07241v2
[7] Y. Liu, L. Lu, J. Jin, L. Sun, and A. Fanelli, "XAttnMark: Learning Robust Audio Watermarking with Cross-Attention," Proceedings of the 42nd International Conference on Machine Learning (ICML), PMLR, Vol. 267, pp. 38987-39015, 2025. https://proceedings.mlr.press/v267/liu25ap.html
[8] X. Wang, L. Li, Y. Wang, L. Jin, Q. Guo, and C. Maple, "No Time to Collapse: Unlocking Robustness and Multiplexed Capacity in Frozen Audio Watermarkers," arXiv:2609.29737v1, 2026. https://arxiv.org/abs/2609.29737v1
[9] J. Yamagishi, C. Veaux, and K. MacDonald, "CSTR VCTK Corpus: English Multi-speaker Corpus for CSTR Voice Cloning Toolkit (version 0.92)," University of Edinburgh, CSTR, 2019. https://doi.org/10.7488/ds/2645